VietinBank

Exploration Data Analysis & Feature Engineering

2022/08, bigdata

Where are we?

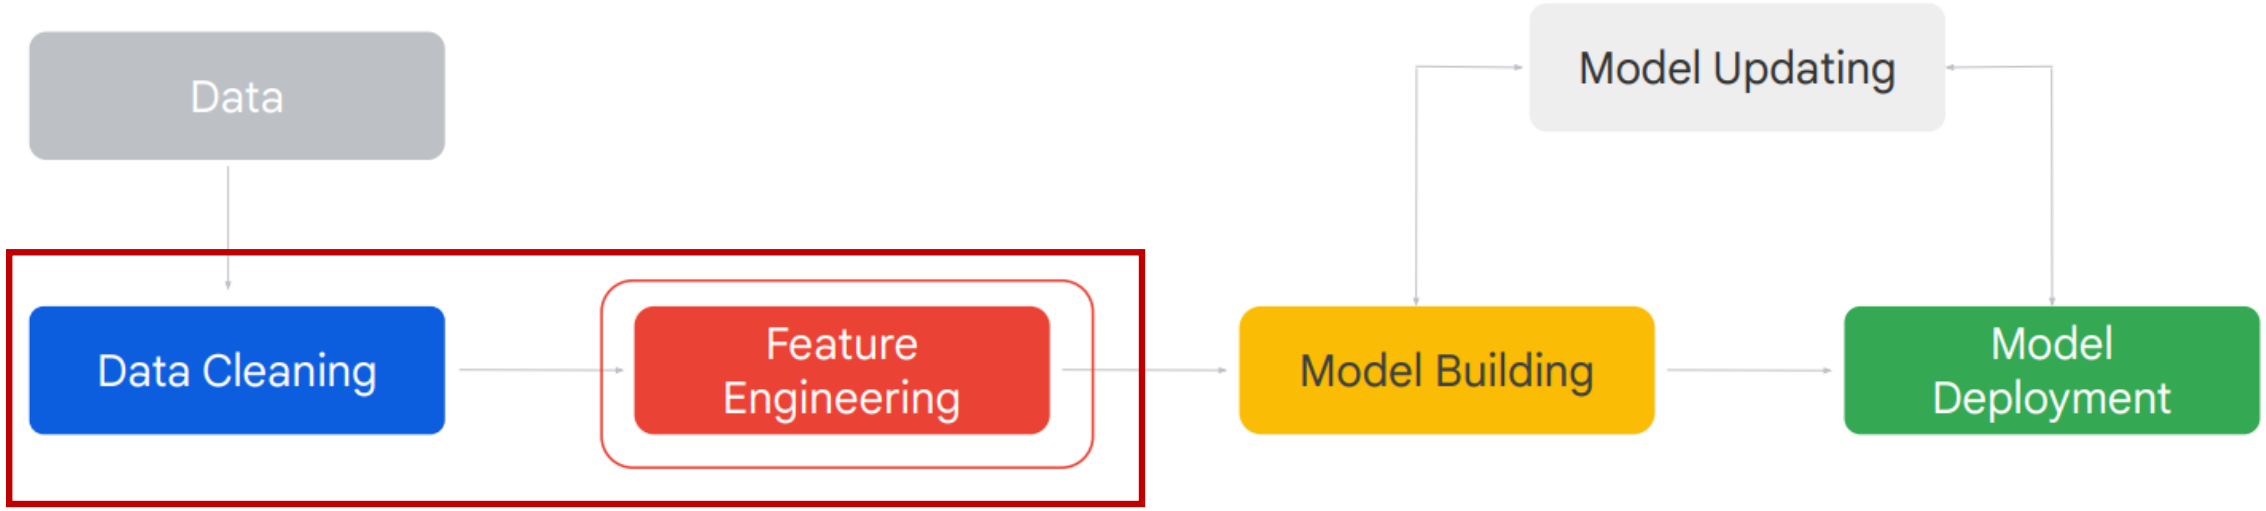
Data
Data Cleaning
Feature Engineering
Model Building
Model Updating
Model Deployment

Chủ đề buổi học

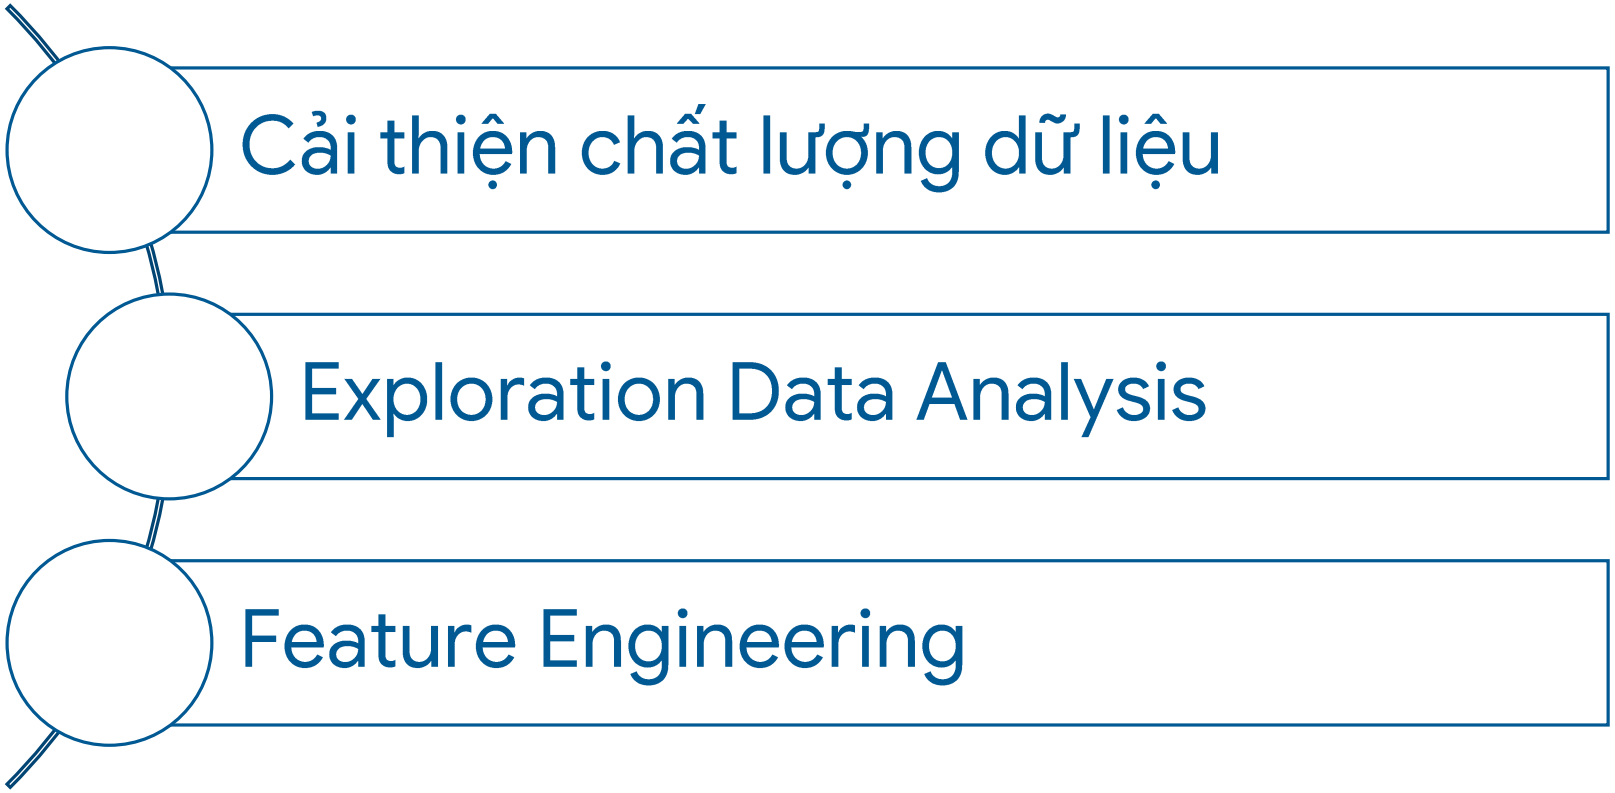

80%

phần trăm thời gian của Data Scientist là data preparing

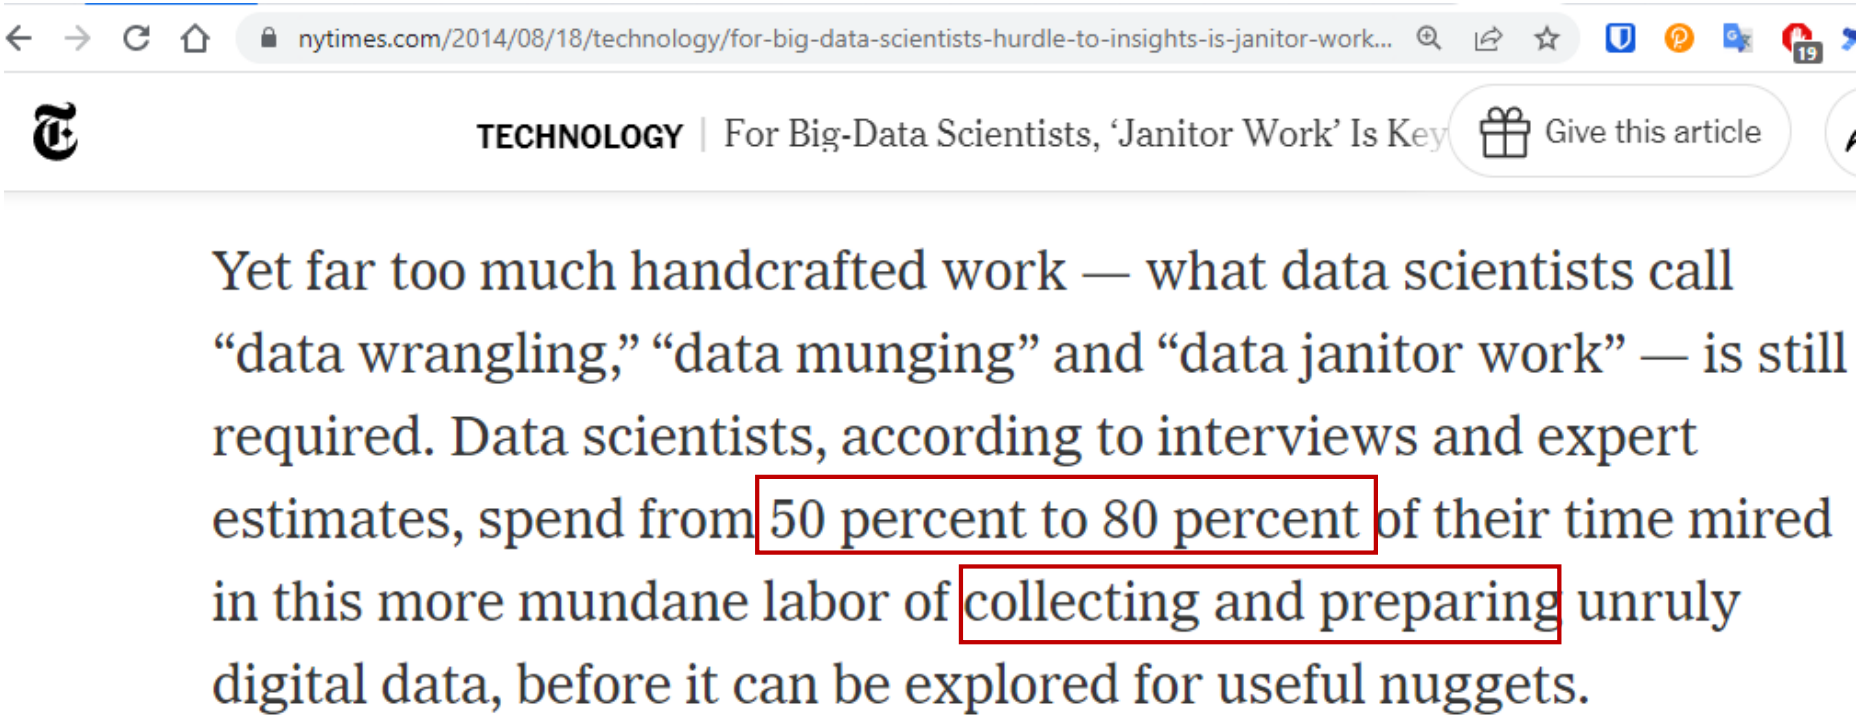

Clean data

Chất lượng dữ liệu cho model

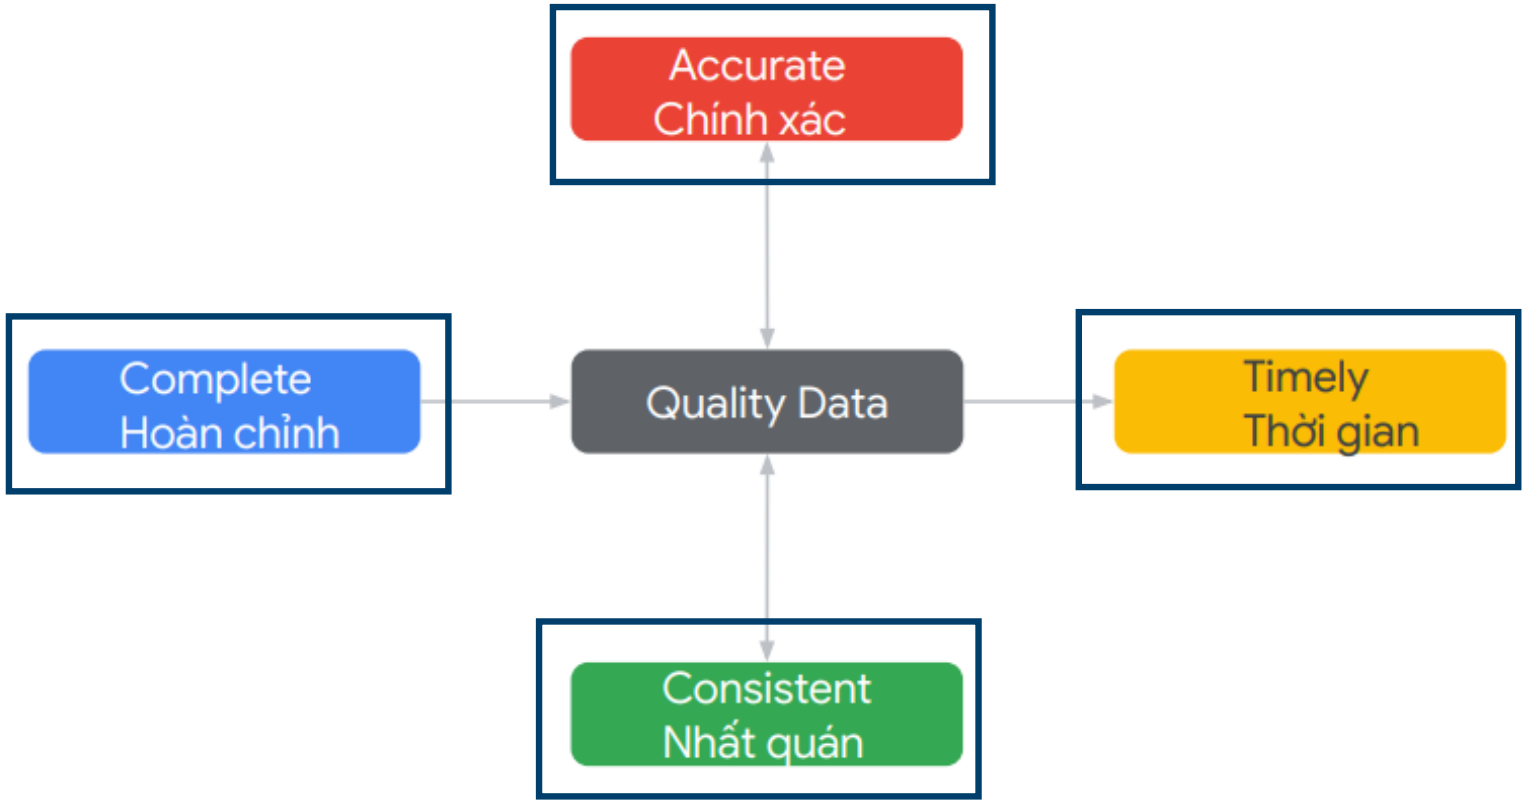

Clean data

Cải thiện chất lượng dữ liệu

1. Resolve Missing Values
2. Convert the Date feature column to Datetime Format
3. Parse date/time features
4. Remove unwanted values
5. Convert categorical columns to “one-hot encodings”

Clean data

Missing value

```
1 data_balance.isnull().sum()
```

```
CIF                    0
cob_dt                 0
current_bal            0
prv_month              0
prv_month_bal          0
prv_year          123947
prv_year_bal      123947
next_1month            0
next_1month_bal        0
next_2months       10601
next_2months_bal   10601
next_3months       21184
next_3months_bal   21184
dtype: int64
```

```
1 print(data_balance['prv_year_bal'])
2 print(data_balance['prv_year_bal'].isnull())
```

```
0         2.100000e+09
1         1.880000e+09
2                  NaN
3                  NaN
4                  NaN
              ...
172129             NaN
172130             NaN
172131    4.038250e+09
172132             NaN
172133             NaN
Name: prv_year_bal, Length: 172134, dtype: float64
0         False
1         False
2          True
3          True
4          True
          ...
172129     True
172130     True
172131    False
172132     True
172133     True
Name: prv_year_bal, Length: 172134, dtype: bool
```

Clean data

Missing value

VietinBank

Clear missing/ null value

```
# Bỏ những feature null value
data_balance = data_balance[~data_balance['prv_year_bal'].isnull()]
```

```
# Fill feature null với avg / mean / max / most frequence value
mean_value = data_balance['prv_year_bal'].mean()

data_balance['prv_year_bal'].fillna(mean_value,inplace = True)
```

👉 https://scikit-learn.org/stable/modules/generated/sklearn.impute.SimpleImputer.html

Clean data

Date & time data

Data với dữ liệu datetime

```
1 data_balance.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 172134 entries, 0 to 172133
Data columns (total 13 columns):
 #   Column            Non-Null Count   Dtype
---  ------            --------------   -----
 0   CIF               172134 non-null  int64
 1   cob_dt            172134 non-null  object
 2   current_bal       172134 non-null  float64
 3   prv_month         172134 non-null  object
 4   prv_month_bal     172134 non-null  float64
 5   prv_year          48187 non-null   object
 6   prv_year_bal      48187 non-null   float64
 7   next_1month       172134 non-null  object
 8   next_1month_bal   172134 non-null  float64
 9   next_2months      161533 non-null  object
 10  next_2months_bal  161533 non-null  float64
 11  next_3months      150950 non-null  object
 12  next_3months_bal  150950 non-null  float64
dtypes: float64(6), int64(1), object(6)
memory usage: 17.1+ MB
```

```
1 data_bal['cob_dt'] = pd.to_datetime(data_bal['cob_dt'])
2 data_balance.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 172134 entries, 0 to 172133
Data columns (total 13 columns):
 #   Column            Non-Null Count   Dtype
---  ------            --------------   -----
 0   CIF               172134 non-null  int64
 1   cob_dt            172134 non-null  datetime64[ns]
 2   current_bal       172134 non-null  float64
 3   prv_month         172134 non-null  object
 4   prv_month_bal     172134 non-null  float64
 5   prv_year          48187 non-null   object
 6   prv_year_bal      48187 non-null   float64
 7   next_1month       172134 non-null  object
 8   next_1month_bal   172134 non-null  float64
 9   next_2months      161533 non-null  object
 10  next_2months_bal  161533 non-null  float64
 11  next_3months      150950 non-null  object
 12  next_3months_bal  150950 non-null  float64
dtypes: datetime64[ns](1), float64(6), int64(1), object(5)
memory usage: 17.1+ MB
```

Clean data

Date & time data

Tách date với Ngày / Tháng / Năm

```
1 data_balance['year'] = data_bal['cob_dt'].dt.year
2 data_balance['month'] = data_bal['cob_dt'].dt.month
3 data_balance['day'] = data_bal['cob_dt'].dt.day
4 data_balance.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 172134 entries, 0 to 172133
Data columns (total 16 columns):
 #   Column            Non-Null Count   Dtype
---  ------            --------------   -----
 0   CIF               172134 non-null  int64
 1   cob_dt            172134 non-null  datetime64[ns]
 2   current_bal       172134 non-null  float64
 3   prv_month         172134 non-null  object
 4   prv_month_bal     172134 non-null  float64
 5   prv_year          48187 non-null   object
 6   prv_year_bal      48187 non-null   float64
 7   next_1month       172134 non-null  object
 8   next_1month_bal   172134 non-null  float64
 9   next_2months      161533 non-null  object
 10  next_2months_bal  161533 non-null  float64
 11  next_3months      150950 non-null  object
 12  next_3months_bal  150950 non-null  float64
 13  year              172134 non-null  int64
 14  month             172134 non-null  int64
 15  day               172134 non-null  int64
dtypes: datetime64[ns](1), float64(6), int64(4), object(5)
memory usage: 21.0+ MB
```

Clean data

Un-wanted (outlier) data

Xóa
Outlier data

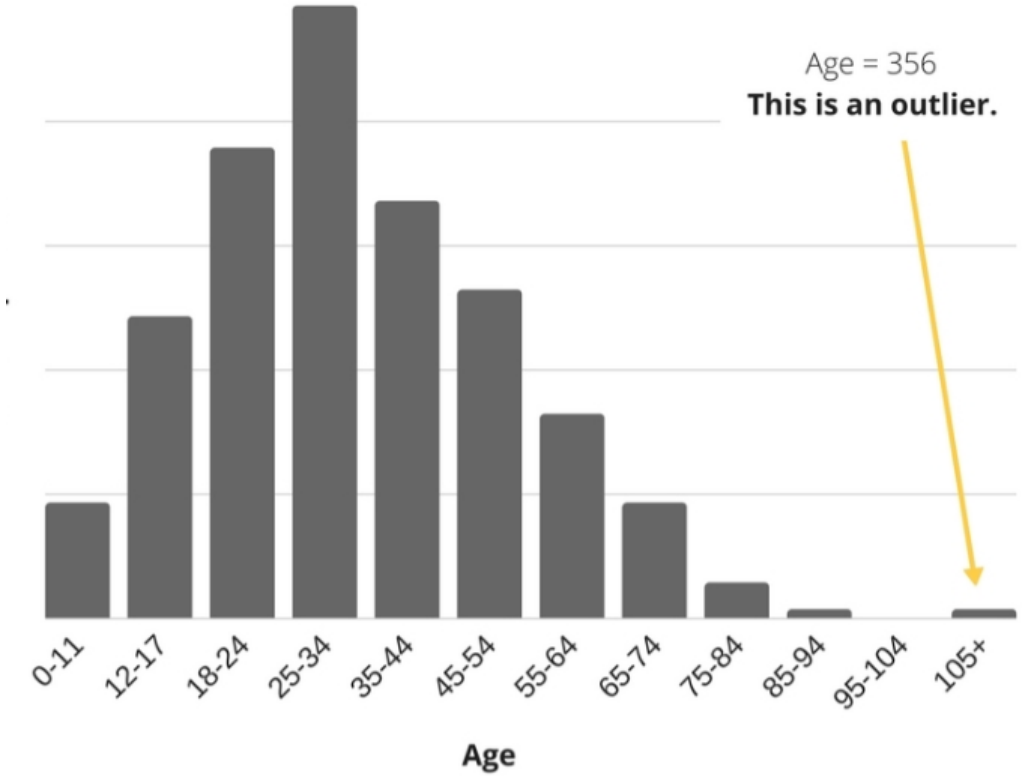

**lưu ý: outlier vs anomaly*

EDA

Exploration Data Analysis

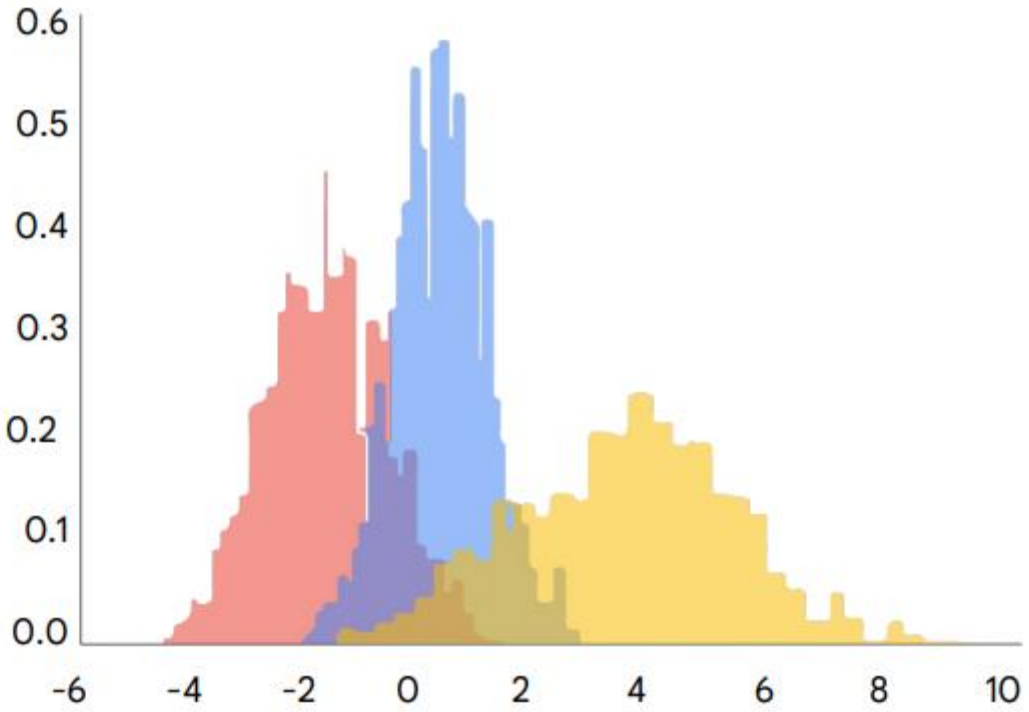

EDA

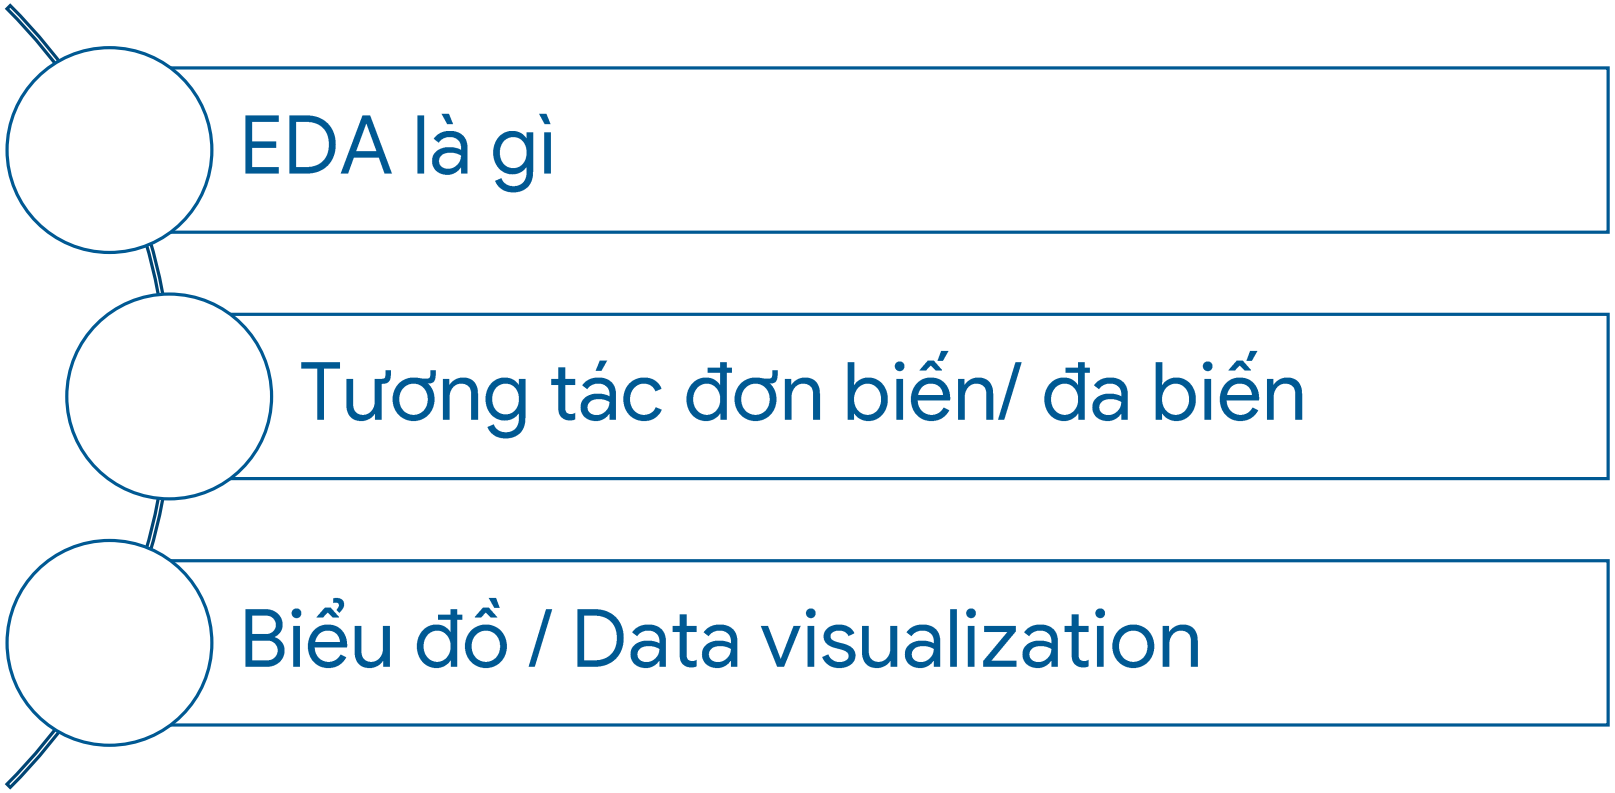
EDA là gì
Tương tác đơn biến/ đa biến
Biểu đồ / Data visualization

EDA

Data

Algorithm

Predictive insight

Decision

EDA

Mục đích của EDA

EDA là đặc biệt quan trọng trong dữ liệu dạng bảng

Ý nghĩa của các trường dữ liệu

Ý nghĩa của bộ dữ liệu, từng trường dữ liệu. Việc hiểu trường dữ liệu quyết định trực tiếp đến quyết định xử lý/ biến đổi về sau

Phân phối xác suất của từng trường

Phân phối xác suất của từng trường dữ liệu

- *Số giá trị trong trường?*
- *Số giá trị khuyết / null?*
- *Giá trị không hợp lệ (outlier)?*
- *Giá trị ngoại lệ (anomaly)?*

Kiểu dữ liệu của mỗi trường

Dạng chuỗi/ số/ ngày tháng.
Tránh bugs khi vận hành model

Mối tương quan giữa các trường dữ liệu

Mối quan hệ tương quan giữa:

- *Trường dữ liệu vs label*
- *Trường dữ liệu với nhau*

Kiểu dữ liệu

Ý nghĩa từng trường dữ liệu

```
1 data_balance.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 172134 entries, 0 to 172133
Data columns (total 13 columns):
 #   Column            Non-Null Count   Dtype
---  ------            --------------   -----
 0   CIF               172134 non-null  int64
 1   cob_dt            172134 non-null  object
 2   current_bal       172134 non-null  float64
 3   prv_month         172134 non-null  object
 4   prv_month_bal     172134 non-null  float64
 5   prv_year          48187 non-null   object
 6   prv_year_bal      48187 non-null   float64
 7   next_1month       172134 non-null  object
 8   next_1month_bal   172134 non-null  float64
 9   next_2months      161533 non-null  object
 10  next_2months_bal  161533 non-null  float64
 11  next_3months      150950 non-null  object
 12  next_3months_bal  150950 non-null  float64
dtypes: float64(6), int64(1), object(6)
memory usage: 17.1+ MB
```

Phân phối xác suất của từng trường dữ liệu (tổng quan)

```
1 data_bal.describe()
```

	cif_no	zbal_current	zbal_prv_month	zbal_prv_year	next_1month_bal
count	1.721340e+05	1.721340e+05	1.721340e+05	4.818700e+04	1.721340e+05
mean	1.131977e+09	2.398324e+09	2.381323e+09	2.265397e+09	2.373845e+09
std	1.233375e+09	3.375059e+09	3.337812e+09	3.082321e+09	3.399013e+09
min	2.000354e+08	2.500000e+01	0.000000e+00	0.000000e+00	0.000000e+00
25%	3.001932e+08	5.000000e+08	5.000000e+08	5.000000e+08	4.799984e+08
50%	3.002620e+08	1.360000e+09	1.350000e+09	1.300000e+09	1.310000e+09
75%	3.014211e+09	3.000000e+09	2.996160e+09	2.930000e+09	2.995641e+09
max	3.017716e+09	1.826119e+11	1.585939e+11	7.452788e+10	1.826119e+11

EDA

Phân phối dữ liệu / tương quan dữ liệu

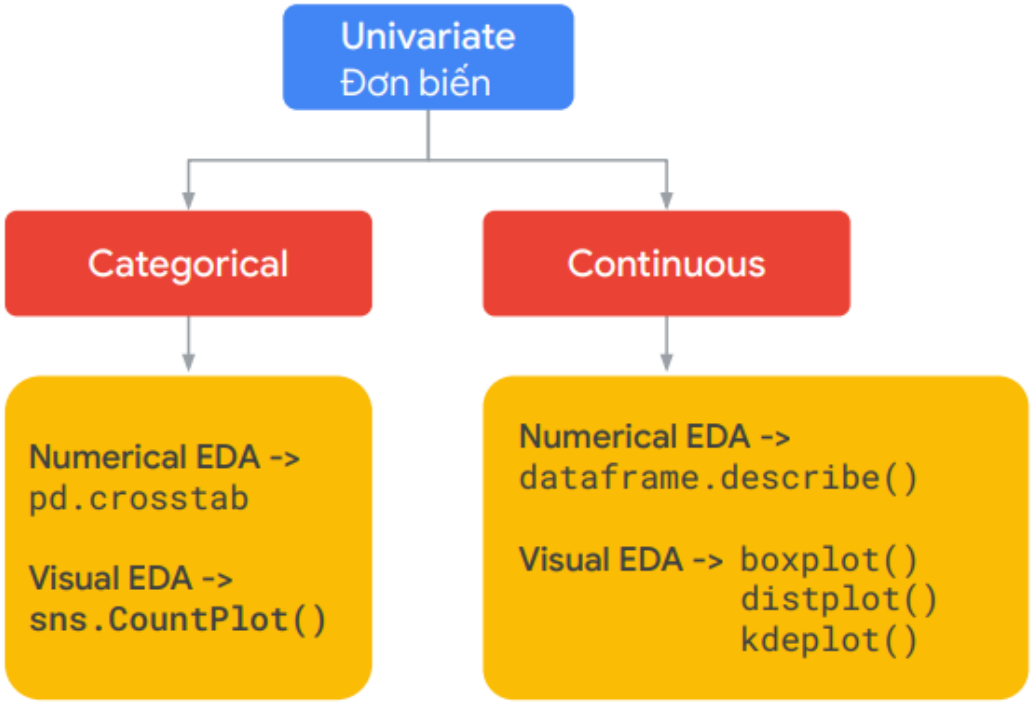

Phân phối dữ liệu đơn biến

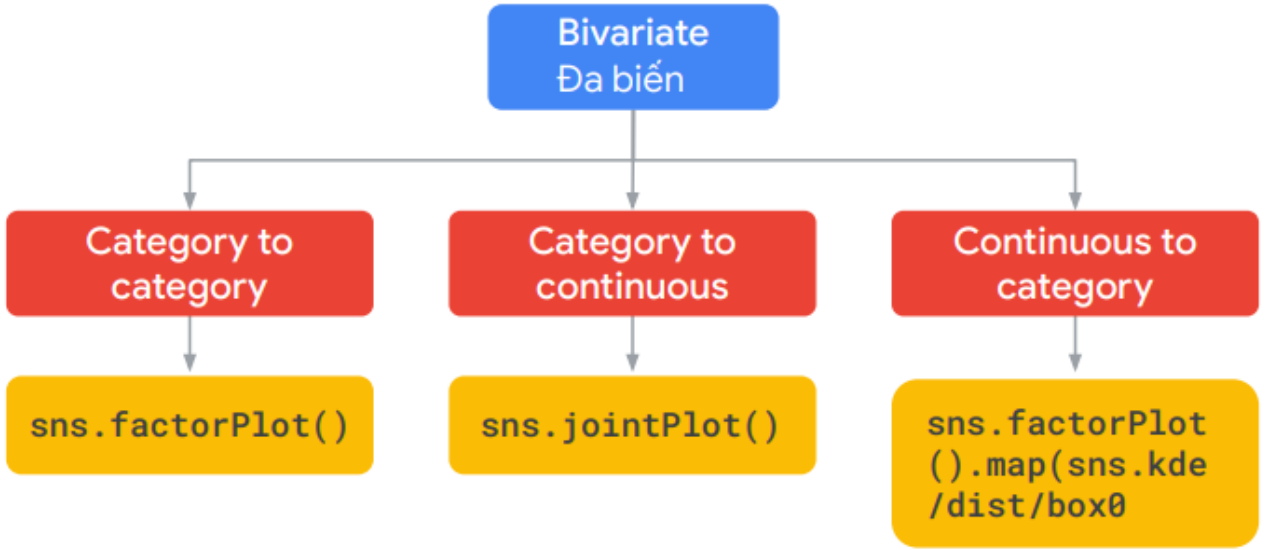

Tương tác đa biến với nhau

Univariate

Đơn biến

```
[17]: sns.countplot(x = `hang_khach_hang`, data=df)

[17]: <matplotlib.axes._subplots.AxesSubplot at 0x7f25ba4ef400>
```

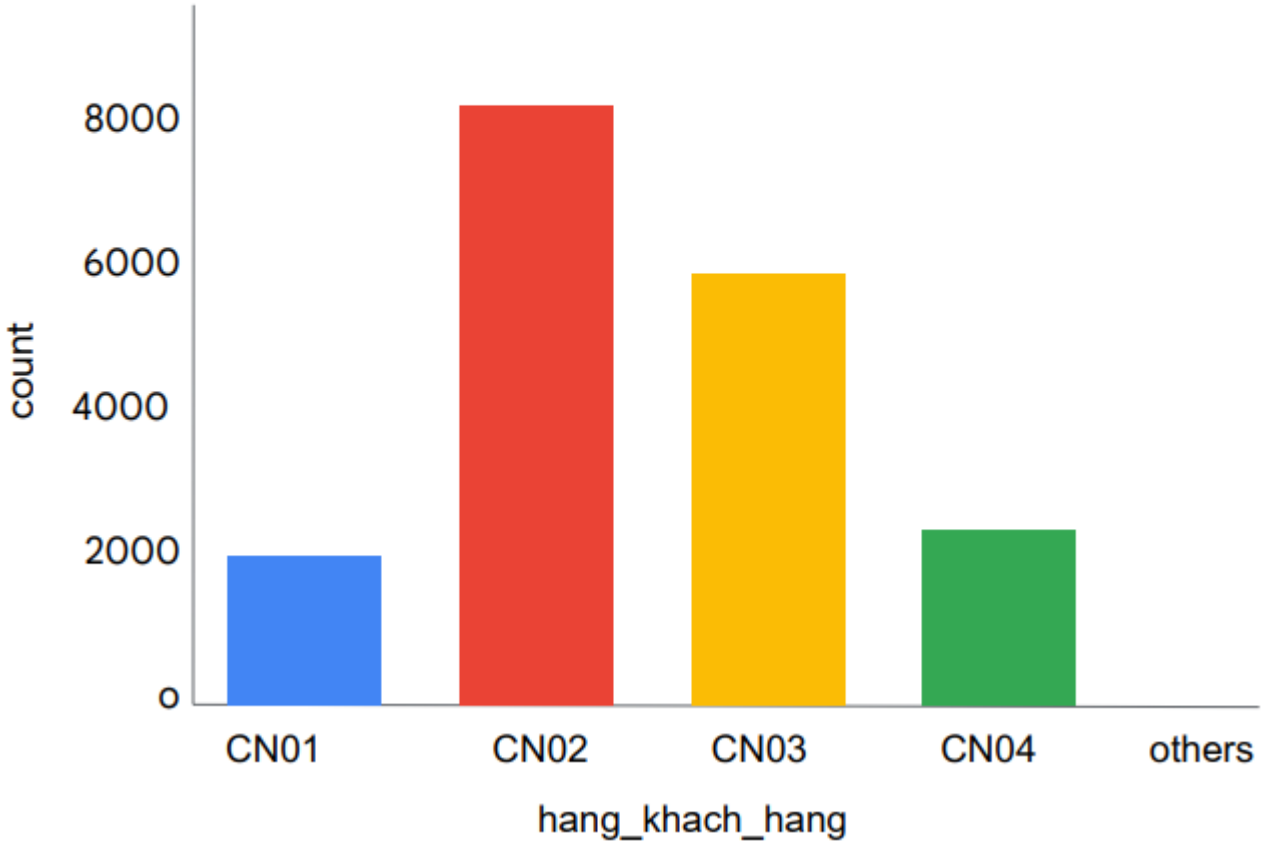

Bivariate

Đa biến

```
ax = sns.regplot(     x="t_cif_age", y="f_balance_vnd",
 fit_reg=False, ci=None, truncate=True, data=trips)
ax.figure.set_size_inches(10, 8)
```

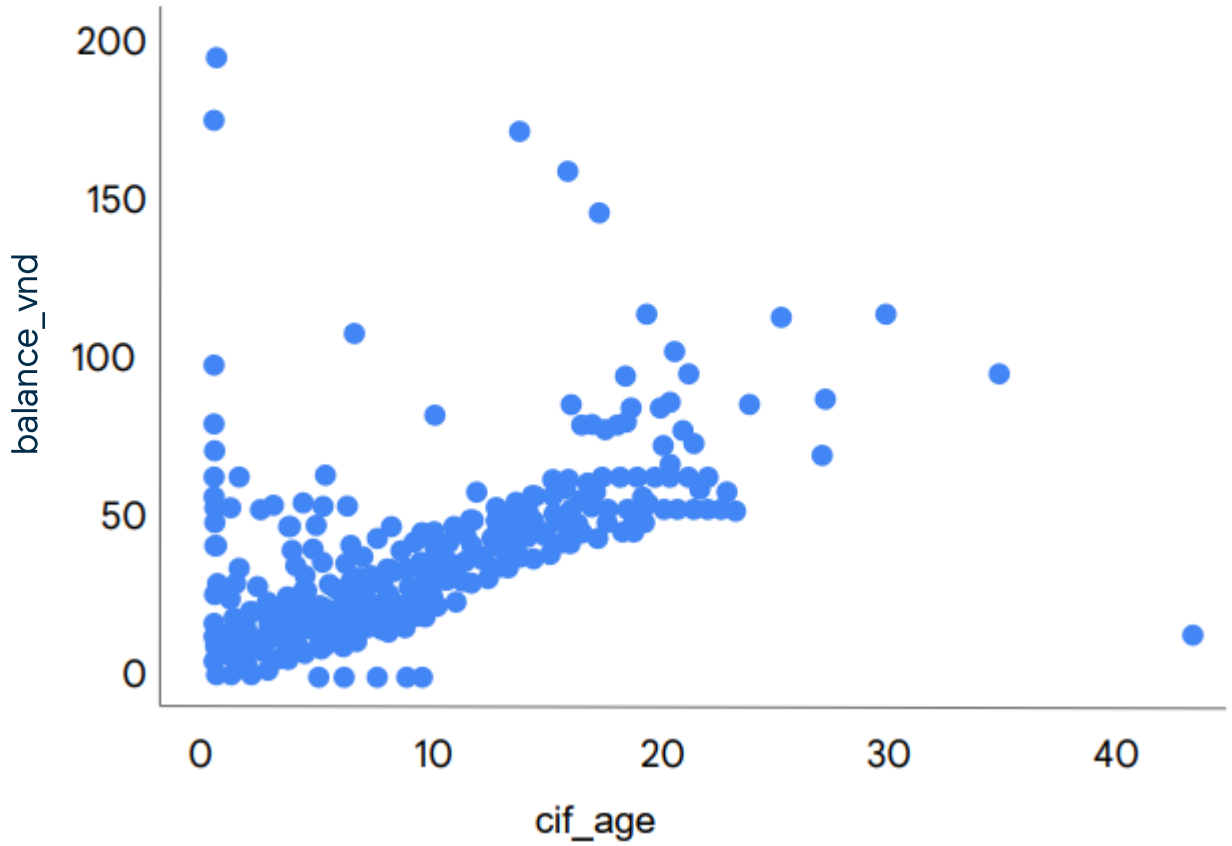

EDA

Biểu đồ

VietinBank

[14]:
```
sns.set_style(`whitegrid`)
data_balance[`balance`].hist(bins=30)
plt.xlabel(`balance`)
```

[14]:
```
Text(0.5, 0, `balance`)
```

Histogram

Biểu diễn phân phối dữ liệu

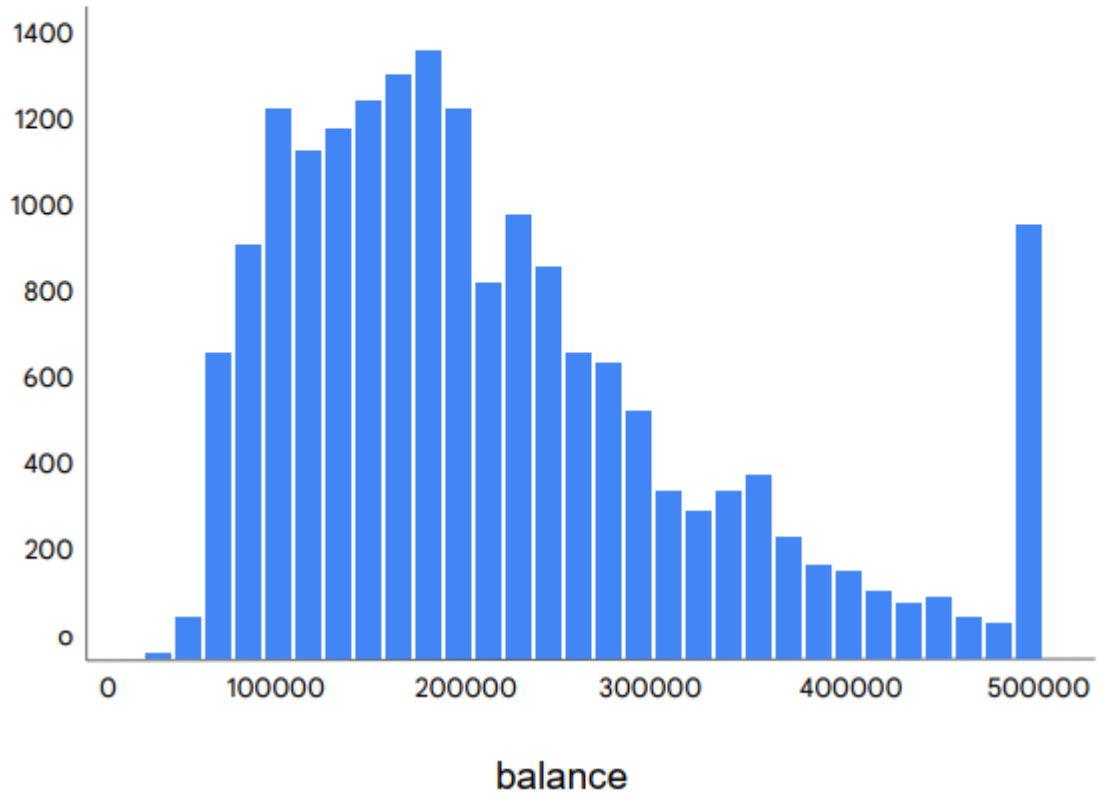

Scatter plot

Biểu diễn mối quan hệ của các trường dữ liệu

```
X = df_USAhousing[`latitude`]
Y = df_USAhousing[`longitude`]

plt.scatter(x,y)
plt.show()
```

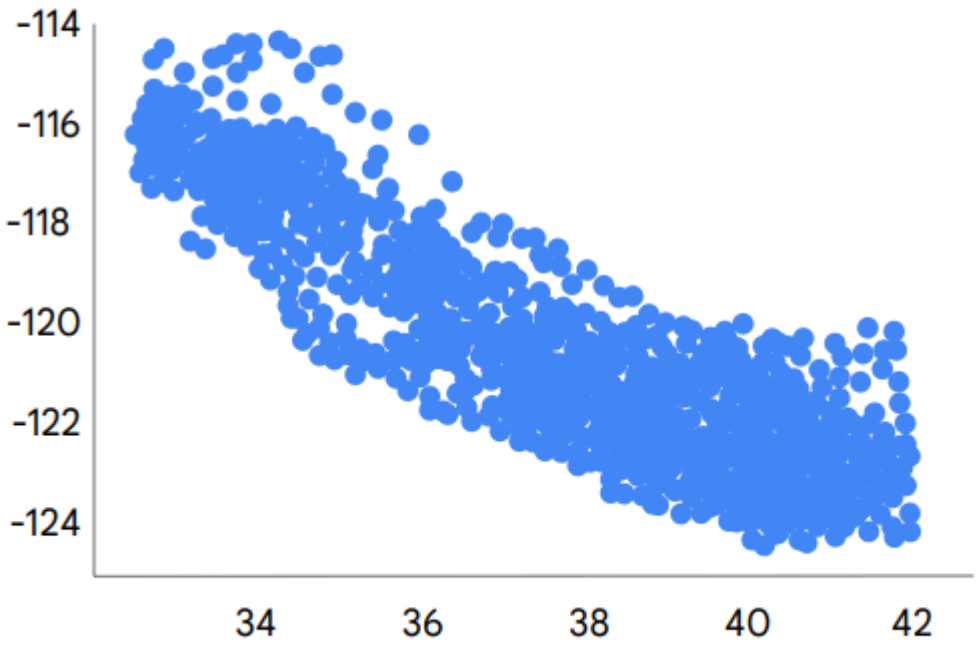

Correlation plot

Biểu diễn mối tương quan của các trường dữ liệu

```
[12]: sns.heatmap(df_USAhousing.corr())

[12]: <matplotlib.axes._subplots.AxesSubplot at 0x7f25ba7c1dd8>
```

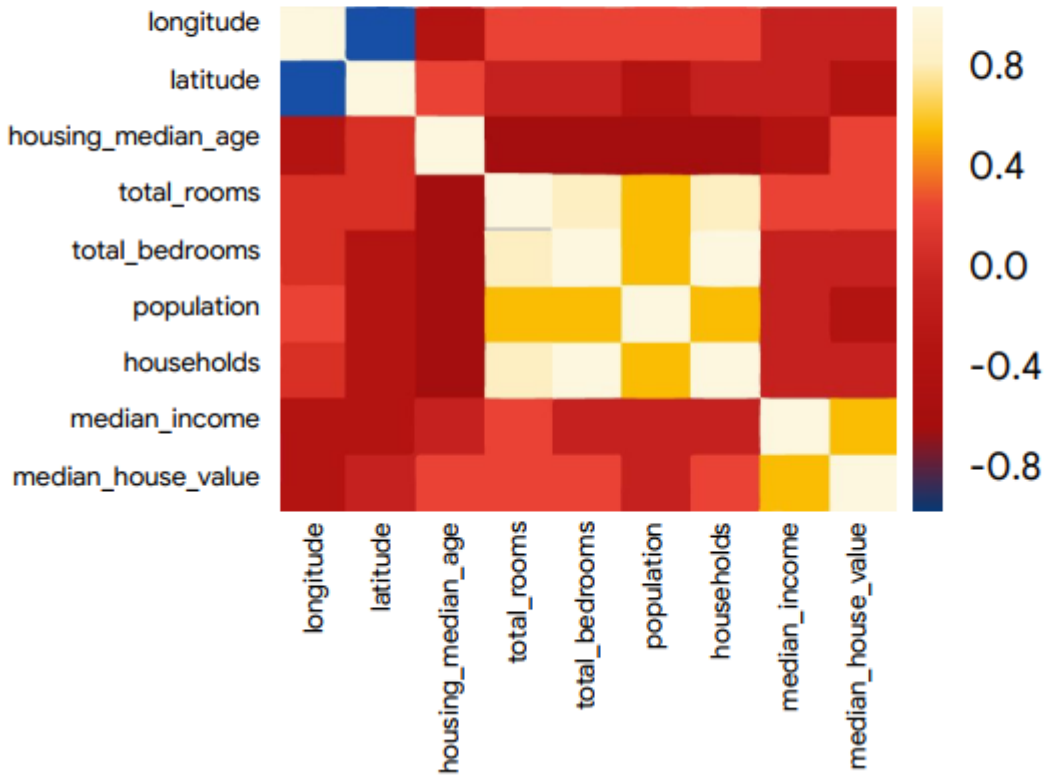

Feature Engineering

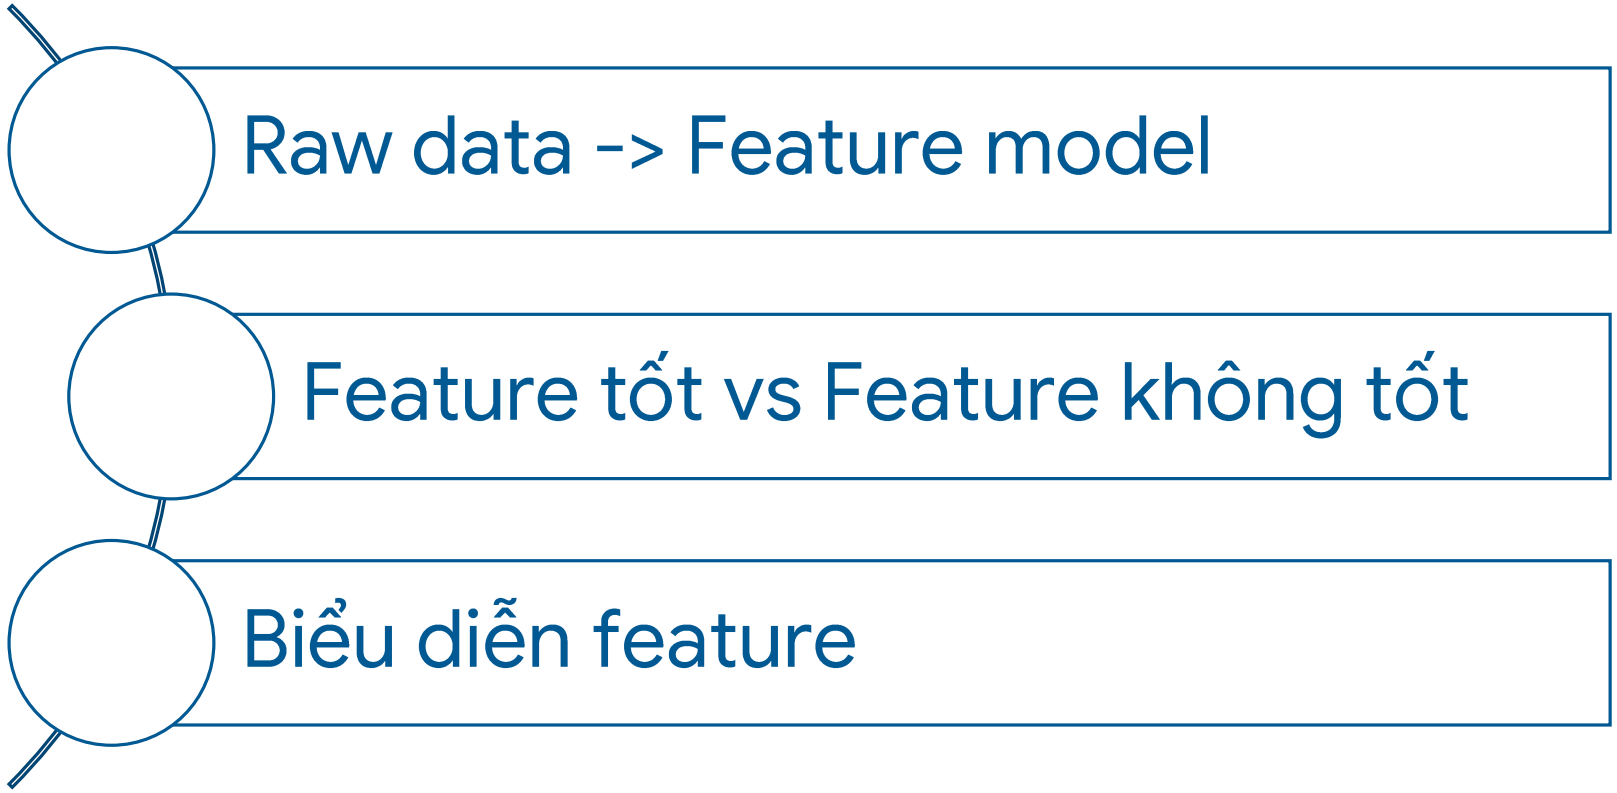

FE

Feature là gì?

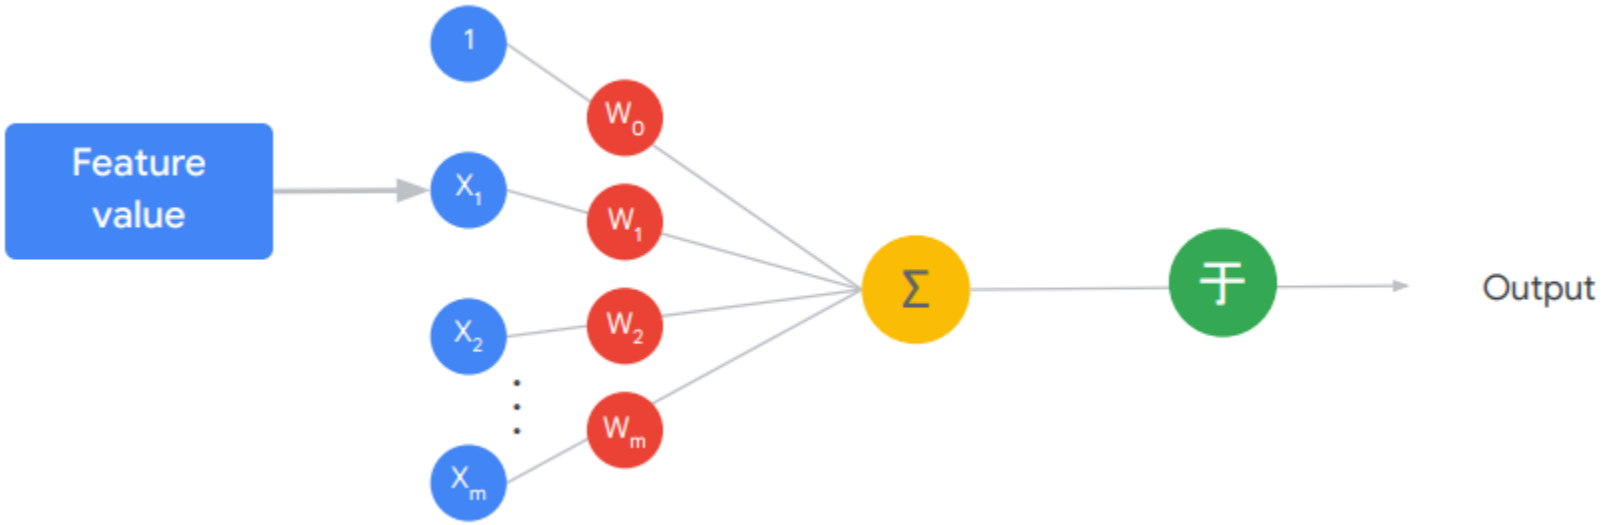

Feature là đặc điểm có thể đo lường của một mẫu
Được sử dụng làm input của ML model

FE

What is FE?

Định nghĩa

Là quá trình biến đổi/ tạo mới feature từ raw data thành feature có khả năng dự đoán trong thuật toán ML

> Feature engineering is the process of transforming raw data into features that better represent the underlying problem to the predictive models, resulting in improved model accuracy on unseen data.
>
> Prof. Andrew Ng

FE

Why FE?

Nhằm cải thiện độ chính xác của thuật toán ML thông qua việc sử dụng dữ liệu đầu vào tốt hơn

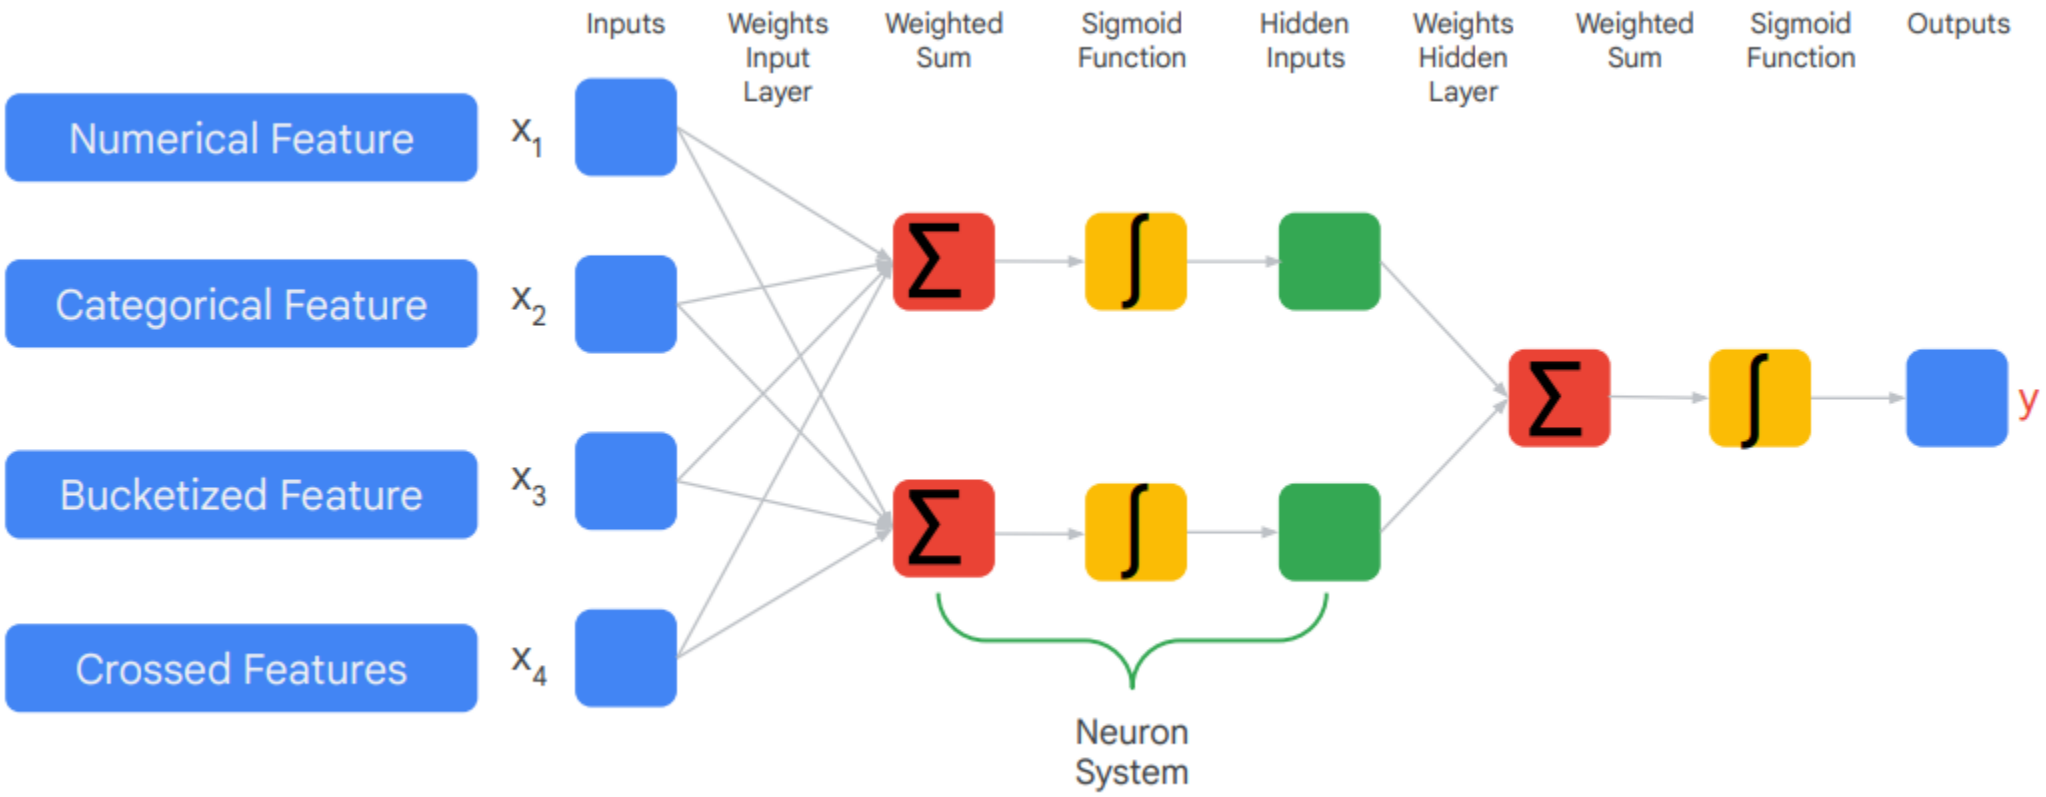

FE

How FE?

Phân tích

- Phân tích yêu cầu
- Tìm kiếm dữ liệu
- EDA

Biểu diễn

- Feature extraction
- Biến đổi feature
- Tạo mới feature

Feature
Numeric
Categorical
Bucketized
Crossed
...

FE

Thế nào là feature tốt?

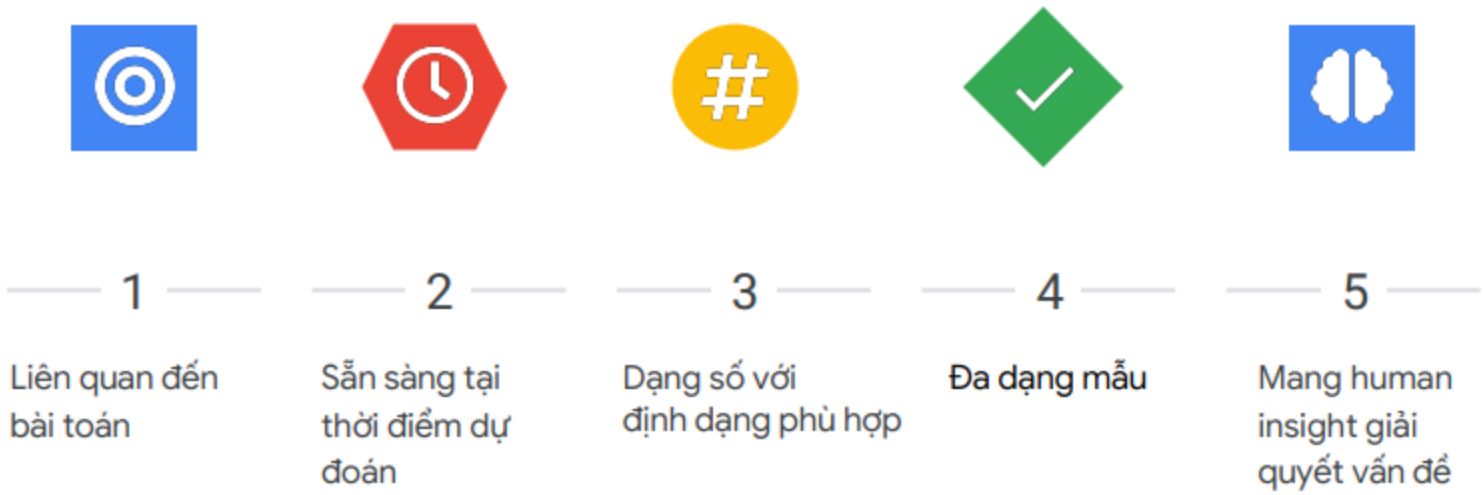

FE

Phân tích

Data nào cần thiết để giải quyết bài toán dự đoán giá nhà?

Diện tích đất
Số phòng ngủ

Lịch sử
giá nhà

Địa điểm

Input data

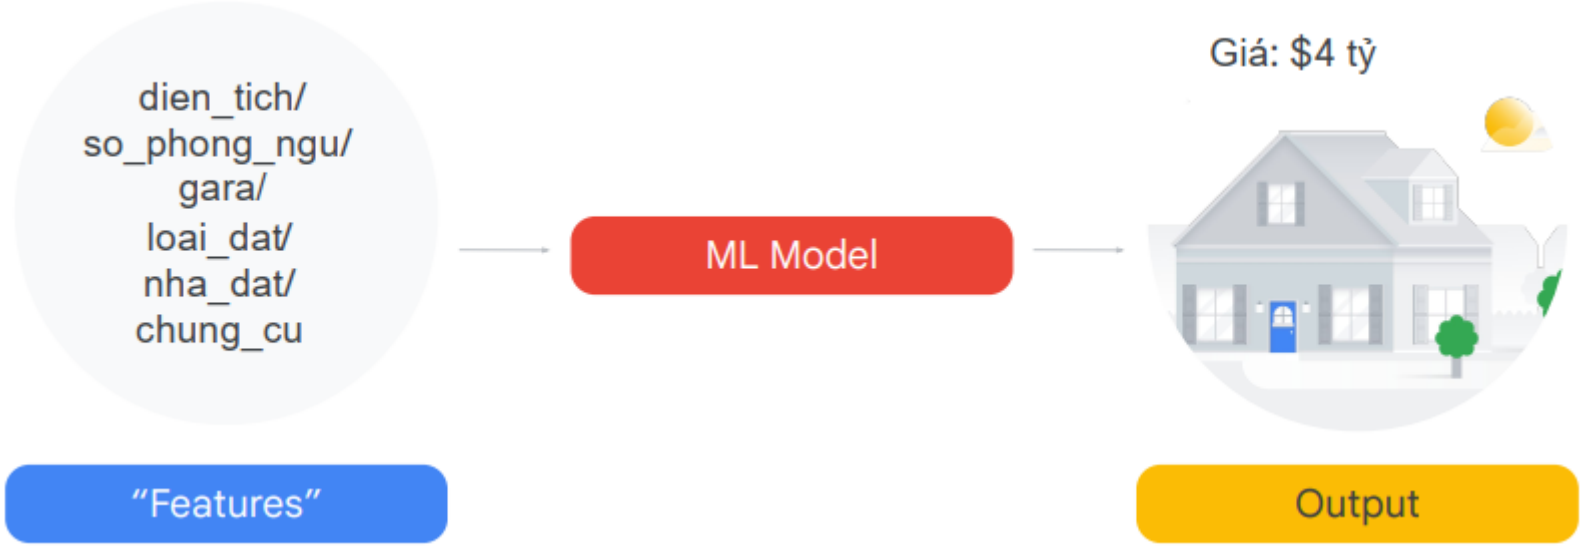

FE

Biểu diễn feature

Feature phải được biểu diễn dưới dạng số

```
{
  "transactionId": 42,
  "name": "Ice Cream",
  "price": 2.50,
  "tags": ["cold", "dessert"],
  "servedBy": {
              "employeeId": 72365,
              "waitTime": 1.4,
              "customerRating": 4},
  "storeLocation": {
  "latitude":   35.3,
  "longitude": -98.7}
},
```

text/categorical

numeric

text/categorical

```
[..., 1, 2.50, …,          ]
[..., 0, 8.99, …,          ]
[..., 0, 3.45, …,          ]
…
```

FE

Biểu diễn feature - numeric

Dạng numeric để nguyên

FE

Biểu diễn feature - id

Dạng đặc biệt/ id nên bỏ

```
{
  "transactionId": 42,
  "name": "Ice Cream",
  "price": 2.50,
  "tags": ["cold", "dessert"],
  "servedBy": {
              "employeeId": 72365,
              "waitTime": 1.4,
              "customerRating": 4},
  "storeLocation": {
  "latitude":   35.3,
  "longitude": -98.7}
},
```

FE

Biểu diễn feature - categorical

Dạng categorical rời rạc nên được encode: one-hot

one-hot encode

Khu vực
KV1
KV2
KV3
KV4
KV5
KV6

KV1	KV2	KV3	KV4	KV5	KV6
0	0	0	1	0	0
1	0	0	0	0	0

FE

Biểu diễn feature - categorical

Dạng categorical nên được encode: ordinal encode
Khi feature mang tính chất thứ tự

ordinal encode

CIF	Hạng khách hàng
xxx	AA+
yyy	A
zzz	BB-
abc	B

CIF	Hạng khách hàng encoded
xxx	4
yyy	3
zzz	2
abc	1

FE

Biểu diễn feature - categorical

Dạng categorical nên được encode: count encode
Khi feature mang tính tần suất

count encode

CIF	Chi nhánh	Rời bỏ
xxx	CN HN	0
yyy	CN 1	1
zzz	CN 1	1
abc	CN HN	1

CIF	Chi nhánh
xxx	1
yyy	2
zzz	2
abc	1

FE

Biểu diễn feature – crossed

Question 1?
Vẽ đường phân lớp

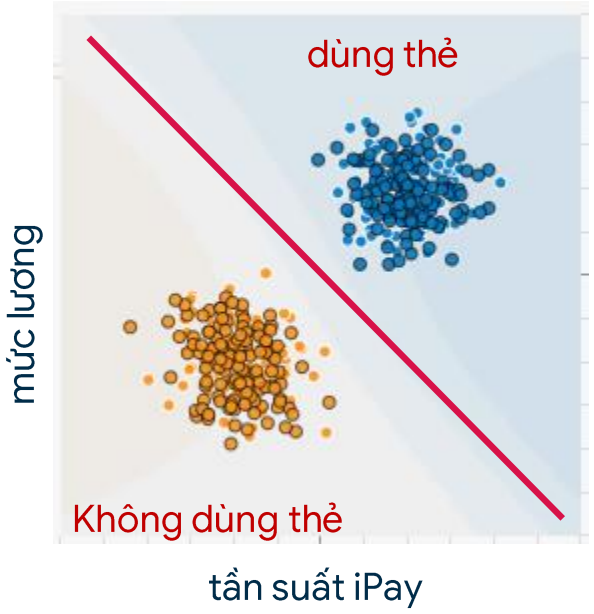

Question 2?
Vẽ đường phân lớp

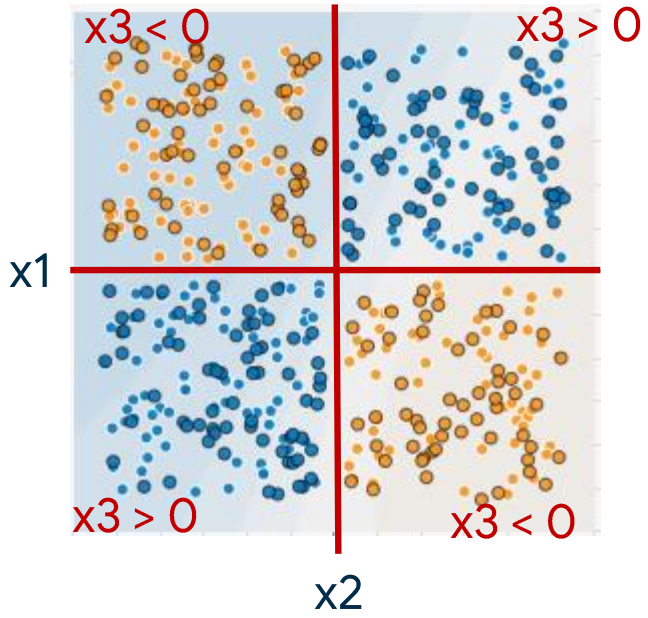

Ý tưởng: x3 = x1*x2

FE

Biểu diễn feature – crossed

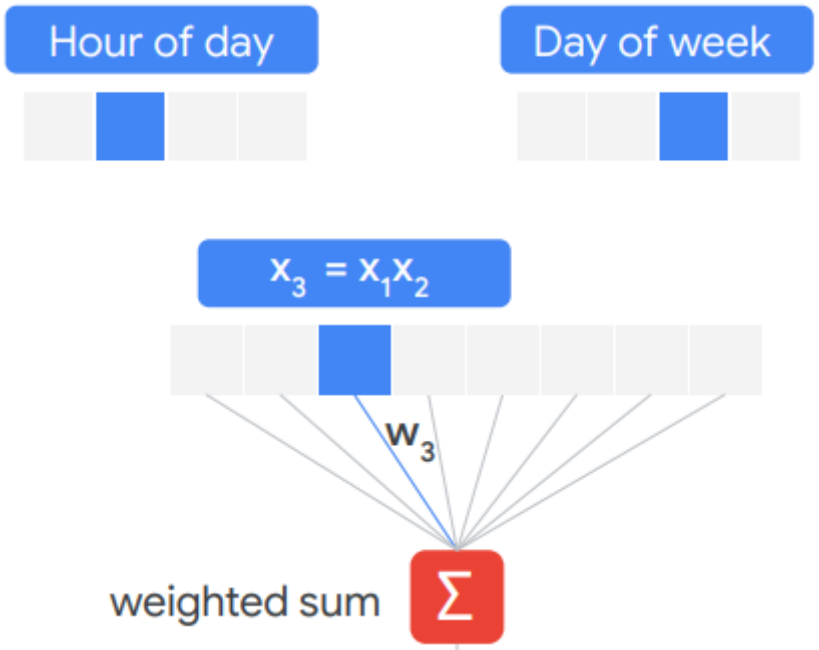

FE

Biểu diễn feature – bins (chia khoảng)

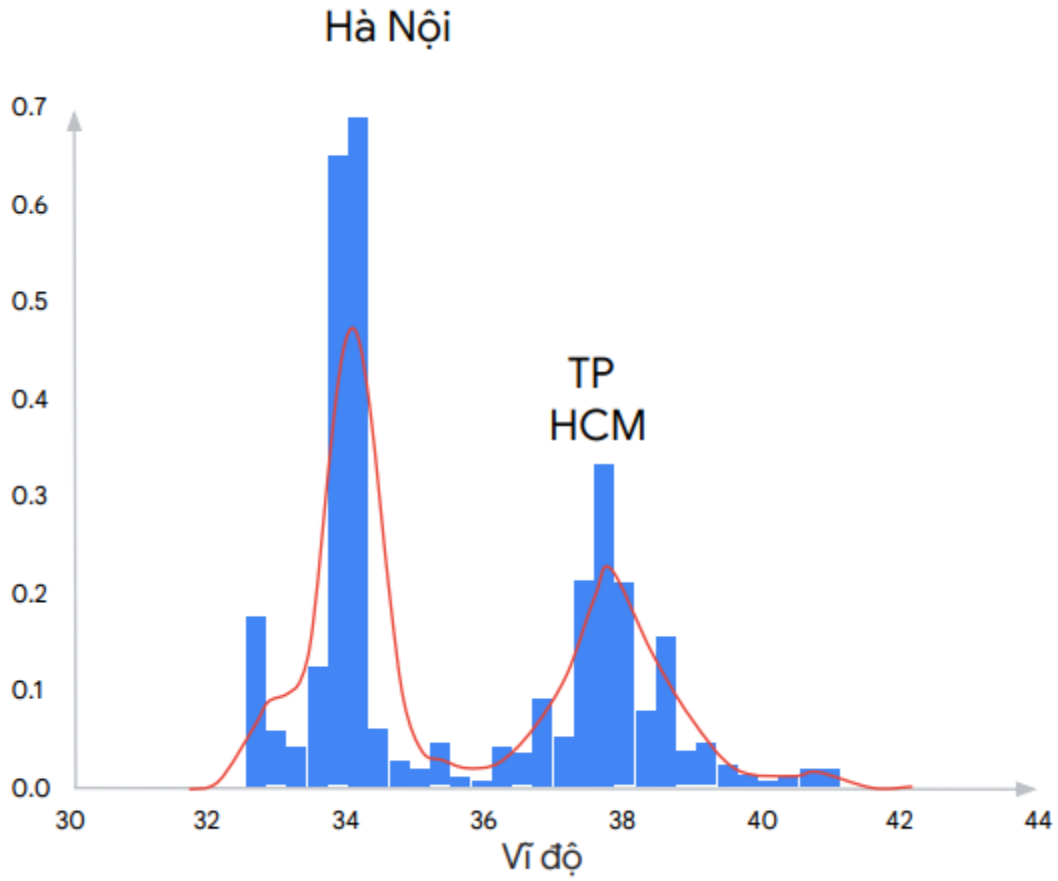

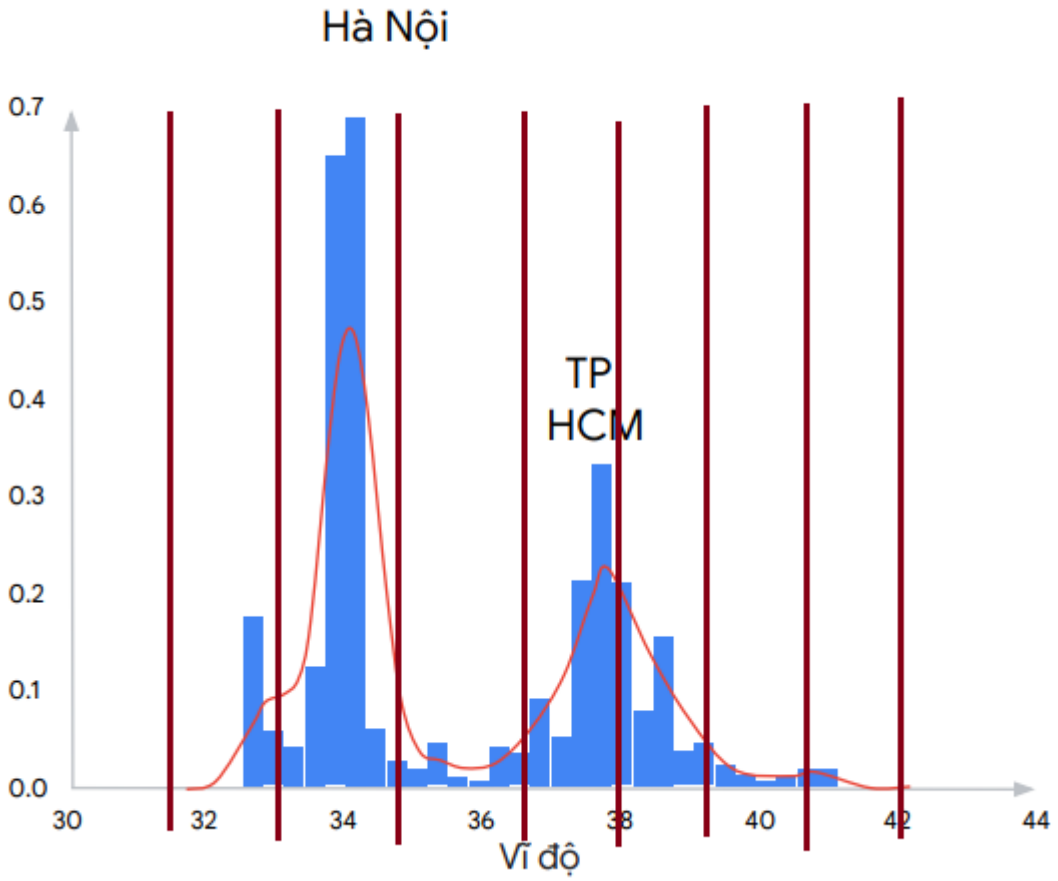

FE

Biểu diễn feature – bins (chia khoảng)

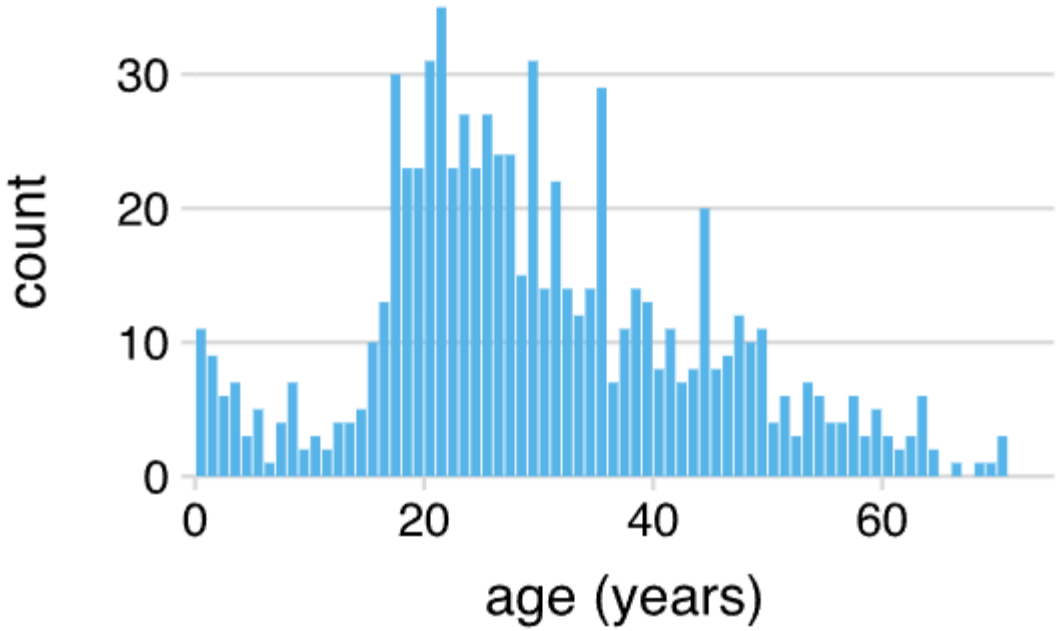

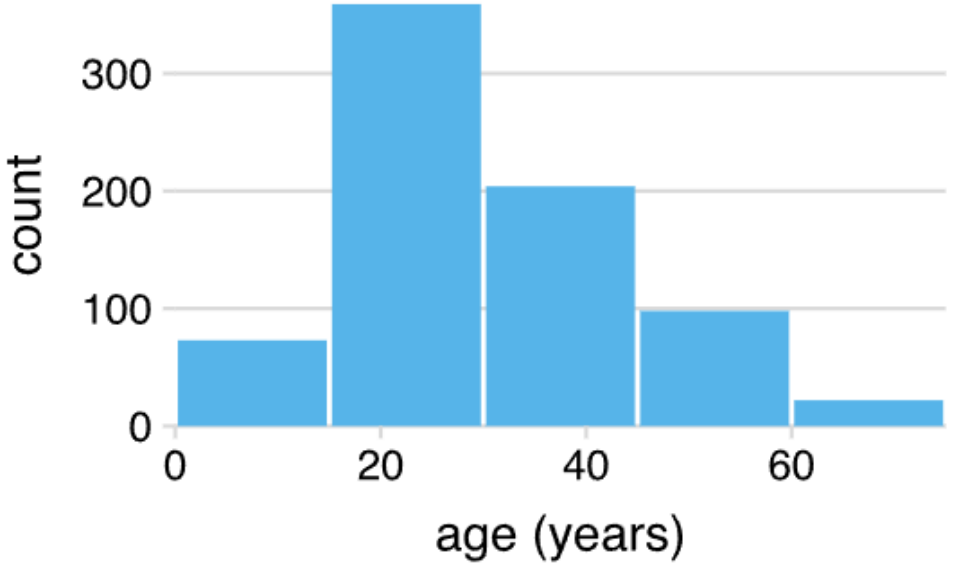

FE

Biểu diễn feature – clipping (anomaly)

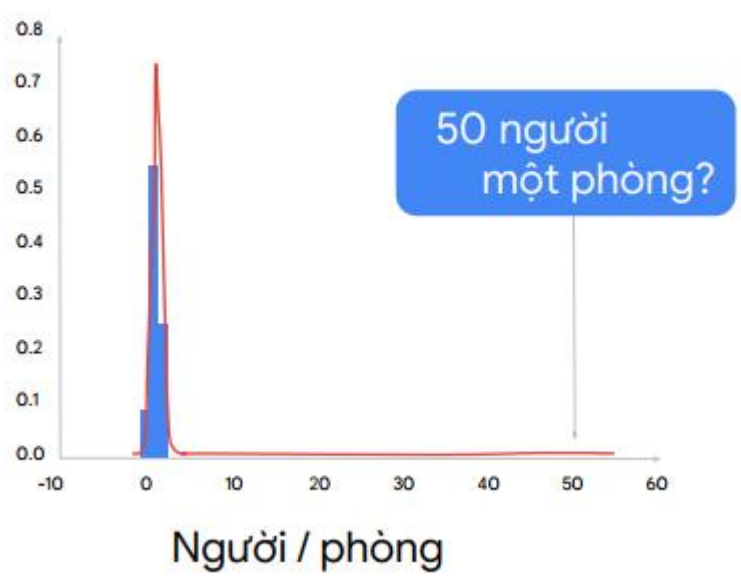

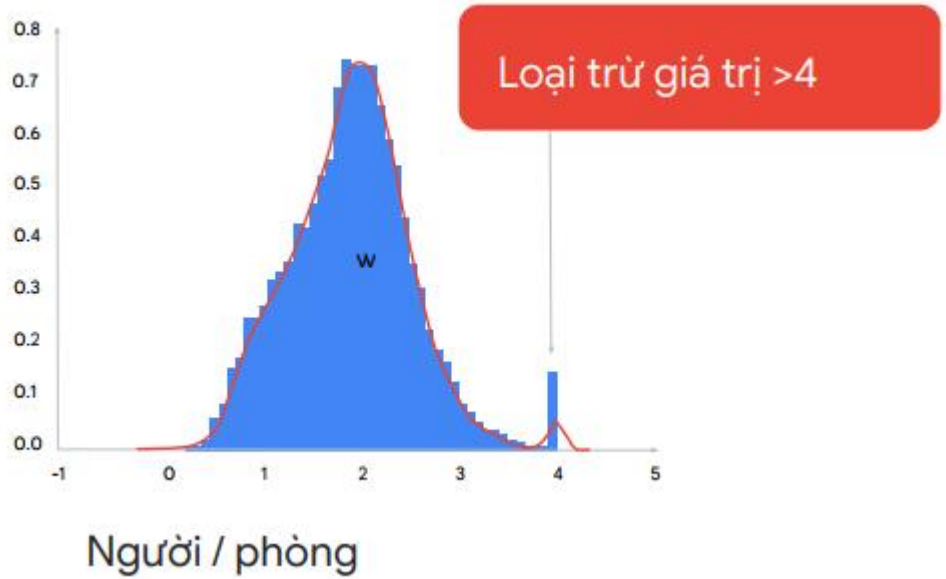

FE

Biểu diễn feature – scale

Playground

https://playground.tensorflow.org

Lab 3

github.com/VietinBank/training-resources